

Chapter 10 隐马尔可夫模型 (hidden Markov model, HMM)

Table of Contents

Chapter 10 隐马尔可夫模型 (hidden Markov model, HMM) 1

10.1 隐马尔可夫模型的基本概念..... 1

 10.1.1 隐马尔可夫模型的定义..... 1

 10.1.2 观测序列的生成过程..... 3

 10.1.3 隐马尔可夫模型的3个基本问题..... 3

10.2 概率计算算法..... 4

 10.2.1 直接计算法..... 4

 10.2.2 前向算法..... 4

 10.2.3 后向算法..... 6

 10.2.4 一些概率与期望的计算..... 6

10.3 学习算法..... 7

 10.3.1 监督学习方法..... 7

 10.3.2 Baum-Welch算法..... 8

 10.3.3 Baum-Welch模型参数估计公式..... 9

10.4 预测算法..... 10

 10.4.1 近似算法..... 10

 10.4.2 维特比算法..... 10

10.1 隐马尔可夫模型的基本概念

10.1.1 隐马尔可夫模型的定义

定义10.1（隐马尔可夫模型） 隐马尔可夫模型是关于时序的概率模型，描述由一个隐藏的马尔可夫链随机生成不可观测的状态随机序列，再由各个状态生成一个观测而产生观测随机序列的过程。隐藏的马尔可夫链随机生成的状态的序列称为状态序列(state sequence)： 每个状态生成一个观测， 而由此产生的观测的随机序列， 称为观测序列(observation sequence)。 序列的每一个位置又可以看作是一个时刻。

隐马尔可夫模型由初始概率分布、状态转移概率分布以及观测概率分布确定。隐马尔可夫模型的形式定义如下：

设Q是所有可能的状态的集合， V是所有可能的观测的集合

$$Q = \{q_1, q_2, \cdots, q_N\}, \quad V = \{v_1, v_2, \cdots, v_M\}$$

I是长度为T的状态序列， O是对应的观测序列。

$$I = (i_1, i_2, \dots, i_T), \quad O = (o_1, o_2, \dots, o_T)$$

$\lambda = (A, B, \pi)$ 称为隐马尔可夫模型的三要素.

A是状态转移概率矩阵: $A = [a_{ij}]_{N \times N}$

$$a_{ij} = P(i_{t+1} = q_j | i_t = q_i), \quad i = 1, 2, \dots, N; j = 1, 2, \dots, N$$

是在时刻 t 处于状态 q_i 的条件下在时刻 $t+1$ 转移到状态 q_j 的概率.

B是观测概率矩阵: $B = [b_j(k)]_{N \times M}$

$$b_j(k) = P(o_t = v_k | i_t = q_j), \quad k = 1, 2, \dots, M; j = 1, 2, \dots, N$$

是在时刻 t 处于状态 q_j 的条件下生成观测 v_k 的概率.

π 是初始状态概率向量: $\pi = (\pi_i)$

$$\pi_i = P(i_1 = q_i), \quad i = 1, 2, \dots, N$$

是时刻 $t=1$ 处于状态 q_i 的概率.

从定义可知, 隐马尔可夫模型作了两个基本假设:

(1)齐次马尔可夫性假设, 即假设隐藏的马尔可夫链在任意时刻 t 的状态只依赖于其前一时刻的状态, 与其他时刻的状态及观测无关, 也与时刻 t 无关

$$P(i_t | i_{t-1}, o_{t-1}, \dots, i_1, o_1) = P(i_t | i_{t-1}), \quad t = 1, 2, \dots, T$$

(2)观测独立性假设, 即假设任意时刻的观测只依赖于该时刻的马尔可夫链的状态, 与其他观测及状态无关.

$$P(o_t | i_T, o_T, i_{T-1}, o_{T-1}, \dots, i_{t+1}, o_{t+1}, i_{t-1}, o_{t-1}, \dots, i_1, o_1) = P(o_t | i_t)$$

例 10.1 (盒子和球模型) 假设有 4 个盒子, 每个盒子里都装有红白两种颜色的球, 盒子里的红白球数由表 10.1 列出.

表10.1各盒子的红白球数

盒子	1	2	3	4
红球数	5	3	6	8
白球数	5	7	4	2

按照下面的方法抽球, 产生一个球的颜色的观测序列:

- 开始, 从4个盒子里以等概率随机选取1个盒子, 从这个盒子里随机抽出1个球, 记录其颜色后, 放回;
- 然后, 从当前盒子随机转移到下一个盒子, 规则是: 如果当前盒子是盒子1, 那么下一盒子一定是盒子2, 如果当前是盒子2或3, 那么分别以概率0.4和0.6转移到左边或右边的盒子, 如果当前是盒子4, 那么各以 0.5 的概率停留在盒子 4或转移到盒子3;

- 确定转移的盒子后，再从这个盒子里随机抽出1个球，记录其颜色，放回；
- 如此下去，重复进行5次，得到一个球的颜色的观测序列；

$O = \{\text{红}, \text{红}, \text{白}, \text{白}, \text{红}\}$

盒子对应状态，状态集合是： $Q = \{\text{盒子1}, \text{盒子2}, \text{盒子3}, \text{盒子4}\}, N = 4$.

球的颜色对应观测，观测集合是： $V = \{\text{红}, \text{白}\}, M = 2$.

$T = 5$

初始概率分布为： $\pi = (0.25, 0.25, 0.25, 0.25)^T$

$$A = \begin{bmatrix} 0 & 1 & 0 & 0 \\ 0.4 & 0 & 0.6 & 0 \\ 0 & 0.4 & 0 & 0.6 \\ 0 & 0 & 0.5 & 0.5 \end{bmatrix}$$

状态转移概率分布为：

$$B = \begin{bmatrix} 0.5 & 0.5 \\ 0.3 & 0.7 \\ 0.6 & 0.4 \\ 0.8 & 0.2 \end{bmatrix}$$

观测概率分布为：

10.1.2 观测序列的生成过程

算法10.1 （观测序列的生成）

输入：隐马尔可夫模型 $\lambda = (A, B, \pi)$ ，观测序列长度 T

输出：观测序列 $O = (o_1, o_2, \dots, o_T)$

- (1) 按照初始状态分布 π 产生状态 i_1 .
- (2) 令 $t = 1$.
- (3) 按照状态 i_t 的观测概率分布 $b_{i_t}(k)$ 生成 o_t .
- (4) 按照状态 i_t 的状态转移概率分布 $a_{i_t i_{t+1}}$ 产生状态 i_{t+1} , $i_{t+1} = 1, 2, \dots, N$.
- (5) 令 $t = t + 1$; 如果 $t < T$ 转步(3); 否则停止.

10.1.3 隐马尔可夫模型的3个基本问题

(1) 概率计算问题. 给定模型 $\lambda = (A, B, \pi)$ 和观测序列 $O = (o_1, o_2, \dots, o_T)$ ，计算在模型 λ 下观测序列 O 出现的概率 $P(O|\lambda)$.

(2) 学习问题. 已知观测序列，估计模型参数 $\lambda = (A, B, \pi)$ ，使得在该模型下观测序列概率 $P(O|\lambda)$ 最大. 即用极大似然估计的方法估计参数.

(3) 预测问题, 也称为解码 (decoding) 问题. 已知模型 $\lambda = (A, B, \pi)$ 和观测序列 $O = (o_1, o_2, \dots, o_T)$, 求对给定观测序列条件概率 $P(I|O)$ 最大的状态序列 $I = (i_1, i_2, \dots, i_T)$. 即给定观测序列, 求最有可能的对应的状态序列.

10.2 概率计算算法

10.2.1 直接计算法

状态序列 $I = \{i_1, i_2, \dots, i_T\}$ 的概率是:

$$P(I|\lambda) = \pi_{i_1} a_{i_1 i_2} a_{i_2 i_3} \dots a_{i_{T-1} i_T}$$

对固定的状态序列 $I = \{i_1, i_2, \dots, i_T\}$, 观测序列 $O = (o_1, o_2, \dots, o_T)$ 的概率是:

$$P(O|I, \lambda) = b_{i_1}(o_1) b_{i_2}(o_2) \dots b_{i_T}(o_T)$$

O 和 I 同时出现的联合概率为:

$$P(O, I|\lambda) = P(O|I, \lambda) P(I|\lambda) = \pi_{i_1} b_{i_1}(o_1) a_{i_1 i_2} b_{i_2}(o_2) \dots a_{i_{T-1} i_T} b_{i_T}(o_T)$$

$$P(O|\lambda) = \sum_I P(O|I, \lambda) P(I|\lambda) = \sum_{i_1, i_2, \dots, i_T} \pi_{i_1} b_{i_1}(o_1) a_{i_1 i_2} b_{i_2}(o_2) \dots a_{i_{T-1} i_T} b_{i_T}(o_T)$$

但是, 利用上述公式计算量很大, 是 $O(TN^T)$ 阶的, 这种算法不可行.

10.2.2 前向算法

定义 **10.2** (前向概率) 给定隐马尔可夫模型 λ , 定义到时刻 t 部分观测序列为 o_1, o_2, \dots, o_t , 且状态为 q_i 的概率为前向概率, 记作

$$\alpha_t(i) = P(o_1, o_2, \dots, o_t, i_t = q_i | \lambda)$$

算法 **10.2** (观测序列概率的前向算法)

输入: 隐马尔可夫模型 λ , 观测序列 O

输出: 观测序列概率 $P(O|\lambda)$

(1) 初值

$$\alpha_1(i) = \pi_i b_i(o_1), \quad i = 1, 2, \dots, N$$

(2) 递推 $t = 1, 2, \dots, T-1$

$$\alpha_{t+1}(i) = \left[\sum_{j=1}^N \alpha_t(j) a_{ji} \right] b_i(o_{t+1}), \quad i = 1, 2, \dots, N$$

(3) 终止

$$P(O|\lambda) = \sum_{i=1}^N \alpha_T(i)$$




图10.1 前向概率的递推公式




图 10.2 观测序列路径结构

例10.2 考虑盒子和球模型 $\lambda = (A, B, \pi)$, 状态集合 $Q = \{1, 2, 3\}$, 观测集合 $V = \{\text{红}, \text{白}\}$,

$$A = \begin{bmatrix} 0.5 & 0.2 & 0.3 \\ 0.3 & 0.5 & 0.2 \\ 0.2 & 0.3 & 0.5 \end{bmatrix}, \quad B = \begin{bmatrix} 0.5 & 0.5 \\ 0.4 & 0.6 \\ 0.7 & 0.3 \end{bmatrix}, \quad \pi = (0.2, 0.4, 0.4)^T$$

设 $T = 3$, $Q = (\text{红}, \text{白}, \text{红})$, 试用前向算法计算 $P(O|\lambda)$.

解: (1) 计算初值

$$\alpha_1(1) = \pi_1 b_1(o_1) = 0.10$$

$$\alpha_1(2) = \pi_2 b_2(o_1) = 0.16$$

$$\alpha_1(3) = \pi_3 b_3(o_1) = 0.28$$

(2) 递推计算

$$\alpha_2(1) = \left[\sum_{i=1}^3 \alpha_1(i) a_{i1} \right] b_1(o_2) = 0.154 \times 0.5 = 0.077$$

$$\alpha_2(2) = \left[\sum_{i=1}^3 \alpha_1(i) a_{i2} \right] b_2(o_2) = 0.184 \times 0.6 = 0.1104$$

$$\alpha_2(3) = \left[\sum_{i=1}^3 \alpha_1(i) a_{i3} \right] b_3(o_2) = 0.202 \times 0.3 = 0.0606$$

$$\alpha_3(1) = \left[\sum_{i=1}^3 \alpha_2(i) a_{i1} \right] b_1(o_3) = 0.04187$$

$$\alpha_3(2) = \left[\sum_{i=1}^3 \alpha_2(i) a_{i2} \right] b_2(o_3) = 0.03551$$

$$\alpha_3(3) = \left[\sum_{i=1}^3 \alpha_2(i) a_{i3} \right] b_3(o_3) = 0.05284$$

(3) 终止

$$P(O|\lambda) = \sum_{i=1}^3 \alpha_3(i) = 0.13022$$

10.2.3 后向算法

定义10.3（后向概率） 给定隐马尔可夫模型 λ ,定义在时刻 t 状态为 q_i 的条件下,从 $t+1$ 到 T 的部分观测序列为 $O_{t+1}, O_{t+2}, \dots, O_T$ 的概率为后向概率,记作

$$\beta_t(i) = P(o_{t+1}, o_{t+2}, \dots, o_T | i_t = q_i, \lambda)$$

算法10.3（观测序列概率的后向算法）

输入：隐马尔可夫模型 λ ,观测序列 O

输出：观测序列概率 $P(O|\lambda)$

(1) $\beta_T(i) = 1, \quad i = 1, 2, \dots, N$

(2) $\beta_t(i) = \sum_{j=1}^N a_{ij} b_j(o_{t+1}) \beta_{t+1}(j), \quad i = 1, 2, \dots, N, t = T-1, T-2, \dots, 1$

(3) $P(O|\lambda) = \sum_{i=1}^N \pi_i b_i(o_1) \beta_1(i)$




图10.3 后向概率的递推公式

10.2.4 一些概率与期望的计算

利用前向概率和后向概率,可以得到关于单个状态和两个状态概率的计算公式

1. 给定模型 λ 和观测 O ,在时刻 t 处于状态 q_i 的概率,记

$$\gamma_t(i) = P(i_t = q_i | O, \lambda)$$

$$\gamma_t(i) = P(i_t = q_i | O, \lambda) = \frac{P(i_t = q_i, O | \lambda)}{P(O | \lambda)}$$

$$\alpha_t(i)\beta_t(i) = P(i_t = q_i, O | \lambda)$$

$$\gamma_t(i) = \frac{\alpha_t(i)\beta_t(i)}{P(O | \lambda)} = \frac{\alpha_t(i)\beta_t(i)}{\sum_{j=1}^N \alpha_t(j)\beta_t(j)}$$

2. 给定模型 λ 和观测 O , 在时刻 t 处于状态 q_i , 且在时刻 $t+1$ 处于状态 q_j 的概率. 记

$$\xi_t(i, j) = P(i_t = q_i, i_{t+1} = q_j | O, \lambda)$$

$$\xi_t(i, j) = \frac{P(i_t = q_i, i_{t+1} = q_j, O | \lambda)}{P(O | \lambda)} = \frac{P(i_t = q_i, i_{t+1} = q_j, O | \lambda)}{\sum_{i=1}^N \sum_{j=1}^N P(i_t = q_i, i_{t+1} = q_j, O | \lambda)}$$

$$P(i_t = q_i, i_{t+1} = q_j, O | \lambda) = \alpha_t(i)a_{ij}b_j(o_{t+1})\beta_{t+1}(j)$$

$$\xi_t(i, j) = \frac{\alpha_t(i)a_{ij}b_j(o_{t+1})\beta_{t+1}(j)}{\sum_{i=1}^N \sum_{j=1}^N \alpha_t(i)a_{ij}b_j(o_{t+1})\beta_{t+1}(j)}$$

3. 将 $\gamma_t(i)$ 和 $\xi_t(i, j)$ 对各个时刻 t 求和, 可以得到一些有用的期望值

(1) 在观测 O 下状态 i 出现的期望值: $\sum_{i=1}^T \gamma_t(i)$

(2) 在观测 O 下由状态 i 转移的期望值: $\sum_{i=1}^{T-1} \gamma_t(i)$

(3) 观测 O 下由状态 i 转移到状态 j 的期望值: $\sum_{i=1}^{T-1} \xi_t(i, j)$

10.3 学习算法

10.3.1 监督学习方法

假设已给训练数据包含 S 个长度相同的观测序列和对应的状态序列 $\{(O_1, I_1), (O_2, I_2), \dots, (O_S, I_S)\}$, 那么可以利用极大似然估计法来估计隐马尔可夫模型的参数. 具体方法如下.

1. 转移概率 a_{ij} 的估计

设样本中时刻 t 处于状态 i , 时刻 $t+1$ 转移到状态 j 的频数为 A_{ij} , 那么状态转移概率 a_{ij} 的估计是

$$\hat{a}_{ij} = \frac{A_{ij}}{\sum_{j=1}^N A_{ij}}, \quad i = 1, 2, \dots, N; j = 1, 2, \dots, N$$

2. 观测概率 $b_j(k)$ 的估计

设样本中状态为 j 并观测为 k 的频数是 B_{jk} , 那么状态为 j 观测为 k 的概率 $b_j(k)$ 的估计是

$$\hat{b}_j(k) = \frac{B_{jk}}{\sum_{k=1}^M B_{jk}}, \quad j = 1, 2, \dots, N; k = 1, 2, \dots, M$$

3. 初始状态概率 π_i 的估计为 $\hat{\pi}_i$ 为 S 个样本中初始状态 q_i 的频率。

10.3.2 Baum-Welch 算法

假设给定训练数据只包含 S 个长度为 T 的观测序列 $\{O_1, O_2, \dots, O_S\}$ 而没有对应的状态序列, 目标是学习隐马尔可夫模型 $\lambda = (A, B, \pi)$ 的参数. 我们将观测序列数据看作观测数据 O , 状态序列数据看作不可观测的隐数据 I , 那么隐马尔可夫模型事实上是一个含有隐变量的概率模型

$$P(O|\lambda) = \sum_I P(O|I, \lambda)P(I|\lambda)$$

它的参数学习可以由 EM 算法实现。

1. 确定完全数据的对数似然函数 $\log P(O, I|\lambda)$

2. EM 算法的 E 步: 求 Q 函数

$$Q(\lambda, \bar{\lambda}) = \sum_I \log P(O, I|\lambda)P(O, I|\bar{\lambda})$$

$$(Q(\lambda, \bar{\lambda}) = \sum_I \log P(O, I|\lambda)P(I|O, \bar{\lambda}), \quad P(I|O, \bar{\lambda}) = P(O, I|\bar{\lambda})/P(O|\bar{\lambda}), \text{ 去掉了对 } \lambda \text{ 而言的常数 } P(O|\bar{\lambda}))$$

$\bar{\lambda}$ 是隐马尔可夫模型参数的当前估计值, λ 是要极大化的隐马尔可夫模型参数.

$$P(O, I|\lambda) = \pi_{i_1} b_{i_1}(o_1) a_{i_1 i_2} b_{i_2}(o_2) \cdots a_{i_{T-1} i_T} b_{i_T}(o_T)$$

$$\begin{aligned} Q(\lambda, \bar{\lambda}) &= \sum_I \log \pi_{i_1} P(O, I|\bar{\lambda}) \\ &+ \sum_I \left(\sum_{t=1}^{T-1} \log a_{i_t i_{t+1}} \right) P(O, I|\bar{\lambda}) + \sum_I \left(\sum_{t=1}^T \log b_{i_t}(o_t) \right) P(O, I|\bar{\lambda}) \end{aligned} \quad (Q)$$

3. EM 算法的 M 步: 极大化 Q 函数 $Q(\lambda, \bar{\lambda})$ 求模型参数 A, B, π

Q 的第一项 $\sum_I \log \pi_i P(O, I | \bar{\lambda}) = \sum_{i=1}^N \log \pi_i P(O, i_1 = i | \bar{\lambda})$

由 $\sum_{i=1}^N \pi_i = 1$ ，采用拉格朗日乘数法

$$L = \sum_{i=1}^N \log \pi_i P(O, i_1 = i | \bar{\lambda}) + \gamma \left(\sum_{i=1}^N \pi_i - 1 \right)$$

$$\frac{\partial}{\partial \pi_i} \left[\sum_{i=1}^N \log \pi_i P(O, i_1 = i | \bar{\lambda}) + \gamma \left(\sum_{i=1}^N \pi_i - 1 \right) \right] = 0$$

$$P(O, i_1 = i | \bar{\lambda}) + \gamma \pi_i = 0$$

$$\gamma = -P(O | \bar{\lambda})$$

$$\pi_i = \frac{P(O, i_1 = i | \bar{\lambda})}{P(O | \bar{\lambda})} \quad (\text{A})$$

Q 的第二项 $\sum_I \left(\sum_{t=1}^{T-1} \log a_{i_t i_{t+1}} \right) P(O, I | \bar{\lambda}) = \sum_{i=1}^N \sum_{j=1}^N \sum_{t=1}^{T-1} \log a_{ij} P(O, i_t = i, i_{t+1} = j | \bar{\lambda})$ ，由于 $\sum_{j=1}^N a_{ij} = 1$

$$a_{ij} = \frac{\sum_{t=1}^{T-1} P(O, i_t = i, i_{t+1} = j | \bar{\lambda})}{\sum_{t=1}^{T-1} P(O, i_t = i | \bar{\lambda})} \quad (\text{B})$$

Q 的第三项 $\sum_I \left(\sum_{t=1}^T \log b_{i_t}(o_t) \right) P(O, I | \bar{\lambda}) = \sum_{j=1}^N \sum_{t=1}^T \log b_j(o_t) P(O, i_t = j | \bar{\lambda})$ ，由于 $\sum_{k=1}^M b_j(k) = 1$

$$b_j(k) = \frac{\sum_{t=1}^T P(O, i_t = j | \bar{\lambda}) I(o_t = v_k)}{\sum_{t=1}^T P(O, i_t = j | \bar{\lambda})} \quad (\text{C})$$

10.3.3 Baum-Welch模型参数估计公式

算法10.4 (Baum-Welch算法)

输入：观测数据 $O = (o_1, o_2, \dots, o_T)$

输出：隐马尔可夫模型参数。

(1) 初始化

对 $n = 0$ ，选取 $a_{ij}^{(0)}, b_j(k)^{(0)}, \pi_i^{(0)}$ ，得到模型 $\lambda^{(0)} = (A^{(0)}, B^{(0)}, \pi^{(0)})$

(2) 递推。对 $n = 1, 2, \dots$,

$$a_{ij}^{(n+1)} = \frac{\sum_{t=1}^{T-1} \xi_t(i, j)}{\sum_{t=1}^{T-1} \gamma_t(i)}, \quad b_j(k)^{(n+1)} = \frac{\sum_{t=1, o_t=v_k}^T \gamma_t(j)}{\sum_{t=1}^T \gamma_t(j)}, \quad \pi_i^{(n+1)} = \gamma_1(i)$$

(3) 终止, 得到模型参数 $\lambda^{(n+1)} = (A^{(n+1)}, B^{(n+1)}, \pi^{(n+1)})$.

10.4 预测算法

10.4.1 近似算法

近似算法的想法是, 在每个时刻 t 选择在该时刻最有可能出现的状态 i_t^* , 从而得到一个状态序

列 $I^* = (i_1^*, i_2^*, \dots, i_r^*)$, 将它作为预测的结果. 给定隐马尔可夫模型 λ 和观测序列 O , 在时刻 t 处于状态 q_i 的概率 $\gamma_t(i)$ 是

$$\gamma_t(i) = \frac{\alpha_t(i)\beta_t(i)}{P(O|\lambda)} = \frac{\alpha_t(i)\beta_t(i)}{\sum_{j=1}^N \alpha_t(j)\beta_t(j)}$$

在每一时刻 t 最有可能的状态 i_t^* 是 $i_t^* = \arg \max_{1 \leq i \leq N} [\gamma_t(i)]$, $t = 1, 2, \dots, T$.

10.4.2 维特比算法

维特比算法实际是用动态规划解隐马尔可夫模型预测问题, 即用动态规划 (dynamic programming) 求概率最大路径 (最优路径). 这时一条路径对应着一个状态序列.

定义在时刻 t 状态为 i 的所有单个路径 (i_1, i_2, \dots, i_t) 中概率最大值为

$$\delta_t(i) = \max_{i_1, i_2, \dots, i_{t-1}} P(i_t = i, i_{t-1}, \dots, i_1, o_t, \dots, o_1 | \lambda), \quad i = 1, 2, \dots, N$$

由定义可得变量 δ 的递推公式:

$$\begin{aligned} \delta_{t+1}(i) &= \max_{i_1, i_2, \dots, i_t} P(i_{t+1} = i, i_t, \dots, i_1, o_{t+1}, \dots, o_1 | \lambda) \\ &= \max_{1 \leq j \leq N} [\delta_t(j) a_{ji}] b_i(o_{t+1}), \quad i = 1, 2, \dots, N; t = 1, 2, \dots, T-1 \end{aligned}$$

定义在时刻 t 状态为 i 的所有单个路径 $(i_1, i_2, \dots, i_{t-1}, i)$ 中概率最大的路径的第 $t-1$ 个结点为

$$\psi_t(i) = \arg \max_{1 \leq j \leq N} [\delta_{t-1}(j) a_{ji}], \quad i = 1, 2, \dots, N$$

算法10.5 (维特比算法)

输入: 模型 $\lambda = (A, B, \pi)$ 和观测 $O = (o_1, o_2, \dots, o_T)$

输出：最优路径 $I^* = (i_1^*, i_2^*, \dots, i_T^*)$

(1) 初始化

$$\begin{aligned}\delta_1(i) &= \pi_i b_i(o_1), i = 1, 2, \dots, N \\ \psi_1(i) &= 0, i = 1, 2, \dots, N\end{aligned}$$

(2) 递推. 对 $t = 2, 3, \dots, T$

$$\begin{aligned}\delta_t(i) &= \max_{1 \leq j \leq N} [\delta_{t-1}(j) a_{ji}] b_i(o_t), i = 1, 2, \dots, N \\ \psi_t(i) &= \arg \max_{1 \leq j \leq N} [\delta_{t-1}(j) a_{ji}], i = 1, 2, \dots, N\end{aligned}$$

(3) 终止

$$\begin{aligned}P^* &= \max_{1 \leq i \leq N} \delta_T(i) \\ i_T^* &= \arg \max_{1 \leq i \leq N} [\delta_T(i)]\end{aligned}$$

4) 最优路径回溯. 对 $t = T - 1, T - 2, \dots, 1$

$$i_t^* = \psi_{t+1}(i_{t+1}^*)$$

求得最优路径 $I^* = (i_1^*, i_2^*, \dots, i_T^*)$.

例10.3 例10.2的模型 $\lambda = (A, B, \pi)$

$$A = \begin{bmatrix} 0.5 & 0.2 & 0.3 \\ 0.3 & 0.5 & 0.2 \\ 0.2 & 0.3 & 0.5 \end{bmatrix}, \quad B = \begin{bmatrix} 0.5 & 0.5 \\ 0.4 & 0.6 \\ 0.7 & 0.3 \end{bmatrix}, \quad \pi = (0.2, 0.4, 0.4)^T$$


已知观测序列 $O=(\text{红}, \text{白}, \text{红})$ ，试求最优状态序列，即最优路径 $I^* = (i_1^*, i_2^*, i_3^*)$.

解 (1) 初始化. 在 $t = 1$ 时，对每一个状态 $i, i = 1, 2, 3$ ，求状态为 i 观测 o_1 为红球的概率，记此概率为 $\delta_1(i)$ ，则

$$\delta_1(i) = \pi_i b_i(o_1) = \pi_i b_i(\text{红}), \quad i = 1, 2, 3$$

代入实际数据 $\delta_1(1) = 0.10, \quad \delta_1(2) = 0.16, \quad \delta_1(3) = 0.28$

记 $\psi_1(i) = 0, \quad i = 1, 2, 3$



(2) 在 $t = 2$ 时, 对每个状态 $i, i = 1, 2, 3$, 求在 $t = 1$ 时状态为 j 观测为红并在 $t = 2$ 时状态为 i 观测 o_2 为白的路径的最大概率, 记此最大概率为 $\delta_2(i)$, 则

$$\delta_2(i) = \max_{1 \leq j \leq 3} [\delta_1(j)a_{ji}]b_i(o_2)$$

$$\psi_2(i) = \arg \max_{1 \leq j \leq 3} [\delta_1(j)a_{ji}], \quad i = 1, 2, 3$$

$$\begin{aligned} \delta_2(1) &= \max_{1 \leq j \leq 3} [\delta_1(j)a_{j1}]b_1(o_2) \\ &= \max_j \{0.10 \times 0.5, 0.16 \times 0.3, 0.28 \times 0.2\} \times 0.5 \\ &= 0.028 \end{aligned}$$

$$\psi_2(1) = 3$$

$$\delta_2(2) = 0.0504, \quad \psi_2(2) = 3$$

$$\delta_2(3) = 0.042, \quad \psi_2(3) = 3$$

$t = 3$ 时

$$\delta_3(i) = \max_{1 \leq j \leq 3} [\delta_2(j)a_{ji}]b_i(o_3)$$

$$\psi_3(i) = \arg \max_{1 \leq j \leq 3} [\delta_2(j)a_{ji}]$$

$$\delta_3(1) = 0.00756, \quad \psi_3(1) = 2$$

$$\delta_3(2) = 0.01008, \quad \psi_3(2) = 2$$

$$\delta_3(3) = 0.0147, \quad \psi_3(3) = 3$$

(3) 以 P^* 表示最优路径的概率

$$P^* = \max_{1 \leq i \leq 3} \delta_3(i) = 0.0147$$

$$i_3^* = \arg \max_i [\delta_3(i)] = 3$$

(4) 由最优路径的终点 i_3^* , 逆向找到 i_2^*, i_1^* .

$$i_2^* = \psi_3(i_3^*) = \psi_3(3) = 3$$

$$i_1^* = \psi_2(i_2^*) = \psi_2(3) = 3$$

最优状态序列为 $I^* = (i_1^*, i_2^*, i_3^*) = (3, 3, 3)$.

作业

习题10.1 给定盒子和球组成的马尔可夫模型 $\lambda = (A, B, \pi)$, 其中,

$$A = \begin{bmatrix} 0.5 & 0.2 & 0.3 \\ 0.3 & 0.5 & 0.2 \\ 0.2 & 0.3 & 0.5 \end{bmatrix}, \quad B = \begin{bmatrix} 0.5 & 0.5 \\ 0.4 & 0.6 \\ 0.7 & 0.3 \end{bmatrix}, \quad \pi = (0.2, 0.4, 0.4)^T$$

设 $T = 4$, $O = (\text{红}, \text{白}, \text{红}, \text{白})$, 试用后向算法计算 $P(O|\lambda)$.